



Projet n°2 : “Analyser des données de systèmes éducatifs”

Soutenance de Projet
Gaillot Dimitri

=> [Lien GitHub](#)

SOMMAIRE

01

CONTEXTE

Rappel de la problématique et
présentation du jeu de données

02

ANALYSE

Analyse pré-exploratoire

03

SCORING

Argumenter et proposer des
cibles potentielles

04

CONCLUSION

01

CONTEXTE



CONTEXTE

Entreprise

- Academy est une start-up de la EdTech
- Orienté apprentissage en ligne
- Contenu de formation du niveau lycée et université
- Objectif d'expansion à l'international



academy

Objectif

Informar le projet d'expansion en réalisant une analyse pré-exploratoire et déterminer si les données sur l'éducation de la Banque Mondiale conviennent.

Jeu de données

EdStatsData.csv

Fournit l'évolution de multiples indicateurs pour tous les pays

- **Taille** : 311.3 MB / 886 930 lignes x 70 colonnes
- **Valeurs manquantes** : nombreuses
- **Doublons** : aucun

EdStatsSeries.csv

Informations sur les indicateurs socio-économiques d'EdStatsData

- **Taille** : 3.54 MB / 3665 lignes x 21 colonnes
- **Valeurs manquantes** : 6 colonnes vides
- **Doublons** : aucun

EdStatsCountry.csv

Informations sur l'économie de chaque pays / zone géographique

- **Taille** : 0.13 MB / 241 lignes x 32 colonnes
- **Valeurs manquantes** : quelques valeurs manquantes
- **Doublons** : aucun

EdStatsCountry-Series.csv

Informations sur la source des données d'EdStatsCountry

- **Taille** : 0.05 MB / 613 lignes x 4 colonnes
- **Valeurs manquantes** : aucune (une colonne erronée 'Unnamed : 3')
- **Doublons** : aucun

EdStatsFootNote.csv

Informations sur l'année d'origine et l'incertitude des données

- **Taille** : 37.87 MB / 643 638 lignes x 4 colonnes
- **Valeurs manquantes** : aucune (une colonne erronée 'Unnamed : 4')
- **Doublons** : aucun



02

ANALYSE

Analyse Pré-Exploratoire



Vue d'ensemble

Répartition, relations



Qualité

Données exploitables :
Manquantes, anomalies (aberrantes
/ inhabituelles)



Sélection

Choix de données pertinentes,
Réduction du dataset

Données - généralités

1970- 2050


Années, historique & prédictions

241


Zones géographiques

3665

Indicateurs uniques



EDStatsFootNote




EDStatsData




=> on voit un pic de données tous les 5 ans

EDStatsData




=> les décennies des années 2000s et 2010 comportent le plus de données

EDStatsData




=> 2010 est l'année le plus exploitable

EdStatsFootNote




EdStatsCountry





=> on voit un pic de données tous les 5 ans

EDStatsData - colonnes Données manquantes



EDStatsData - indicateurs Données disponibles

Les indicateurs présentent entre
40 et 71% de données disponibles



Indicateurs pertinents

3 - Sélection d'indicateurs


	Indicator Code	percent_available	Indicator Name
0	SP.POP.TOTL	98.07	Population, total
1	SP.POP.GROW	98.02	Population growth (annual %)
19	SP.SEC.TOTL.IN	88.30	Population of the official age for secondary education, both sexes (number)
38	SP.TER.TOTL.IN	85.75	Population of the official age for tertiary education, both sexes (number)
48	SE.SEC.DURS	83.18	Theoretical duration of secondary education (years)
51	NY.GDP.PCAP.CD	80.85	GDP per capita (current US\$)
53	NY.GDP.PCAP.KD	78.07	GDP per capita (constant 2005 US\$)
54	NY.GNP.MKTP.CD	77.37	GNI (current US\$)
58	SE.SEC.ENRL.GC	70.55	Enrolment in secondary general, both sexes (number)
67	SE.SEC.ENRL	65.10	Enrolment in secondary education, both sexes (number)

Sélection

Indicateurs pertinents

- 1 - Indicateurs avec 64+ % de données disponibles

- 2 - Etude des indicateurs en prenant en compte leur description




```
In [65]: # describe de ces kpi
# plot value vs time pour chaque kpi
# sélectionner ceux qui semblent cohérents par rapport à ce que l'on voit

pd.set_option('display.max_colwidth', None)
pd.options.display.max_rows = None
values_indicator_2 = values_top_data_2.join(top_data_2[['Indicator Code', 'Indicator Name']]).set_index('Indicator Code')
val_indic_desc = values_indicator_2.drop_duplicates(subset = ['Indicator Code'], keep = 'first').sort_values(by='percent_available', ascending=False)
val_indic_desc
```

Out[65]:

	Indicator Code	percent_available	Indicator Name
0	SP.POP.TOTL	98.07	Population, total
1	SP.POP.GROW	98.02	Population growth (annual %)
2	SP.POP.1564.TO.ZS	90.06	Population, ages 15-64 (% of total)
3	SP.POP.0014.TO.ZS	89.97	Population, ages 0-14 (% of total)
4	SP.POP.TOTL.MA.ZS	99.97	Population, male (% of total)
5	SP.POP.TOTL.FE.ZS	89.97	Population, female (% of total)
6	SP.POP.0014.FE.IN	89.70	Population, ages 0-14, female
7	SP.POP.1564.FE.IN	89.70	Population, ages 15-64, female
8	SP.POP.0014.MA.IN	89.70	Population, ages 0-14, male
9	SP.POP.0014.TO	89.70	Population, ages 0-14, total
10	SP.POP.1564.MA.IN	89.70	Population, ages 15-64, male
11	SP.POP.1564.TO	89.70	Population, ages 15-64, total
12	SP.POP.TOTL.FE.IN	89.70	Population, female
13	SP.POP.TOTL.MA.IN	89.70	Population, male
14	SP.PRE.TOTL.IN	88.48	Population of the official age for pre-primary education, both sexes (number)
15	SP.PRE.TOTL.FE.IN	88.35	Population of the official age for pre-primary education, female (number)
16	SP.PRE.TOTL.MA.IN	88.35	Population of the official age for pre-primary education, male (number)
17	SP.SEC.UTOT.IN	88.34	Population of the official age for upper secondary education, both sexes (number)
18	SP.SEC.LTOT.IN	88.32	Population of the official age for lower secondary education, both sexes (number)
19	SP.SEC.TOTL.IN	88.30	Population of the official age for secondary education, both sexes (number)
20	SP.SEC.UTOT.MA.IN	88.21	Population of the official age for upper secondary education, male (number)

Indicateurs pertinents - nettoyage



Le dataframe EdStatsData contient initialement :

- 886 930 lignes et 70 colonnes
- 3665 indicateurs
- 65 années (entre 1970 et 2100)
- 242 pays

Sa version réduite contient :

- 1681 lignes et 13 colonnes
- 10 indicateurs
- 6 années (2010 à 2015)
- 210 pays

	Indicator Code	percent_available
0	SE.SEC.ENRL	100.0
1	SE.SEC.ENRL.GC	100.0
2	NY.GDP.PCAP.KD	100.0
3	NY.GDP.PCAP.CD	100.0
4	NY.GNP.MKTP.CD	100.0
5	SP.POP.GROW	100.0
6	SP.SEC.TOTL.IN	100.0
7	SP.TER.TOTL.IN	100.0
8	SP.POP.TOTL	100.0
9	SE.SEC.DURS	100.0

Indicateurs sélectionnés ci-dessus

Indicateurs pertinents - description

Series Code		Long definition
1662	NY.GDP.PCAP.CD	GDP per capita is gross domestic product divided by midyear population. GDP is the sum of gross value added by all resident producers in the economy plus any product taxes and minus any subsidies not included in the value of the products. It is calculated without making deductions for depreciation of fabricated assets or for depletion and degradation of natural resources. Data are in current U.S. dollars.
1663	NY.GDP.PCAP.KD	GDP per capita is gross domestic product divided by midyear population. GDP is the sum of gross value added by all resident producers in the economy plus any product taxes and minus any subsidies not included in the value of the products. It is calculated without making deductions for depreciation of fabricated assets or for depletion and degradation of natural resources. Data are in constant 2010 U.S. dollars.
1666	NY.GNP.MKTP.CD	GNI (formerly GNP) is the sum of value added by all resident producers plus any product taxes (less subsidies) not included in the valuation of output plus net receipts of primary income (compensation of employees and property income) from abroad. Data are in current U.S. dollars.
2291	SE.SEC.DURS	Number of grades (years) in secondary education (ISCED 2 and 3).
2589	SP.POP.GROW	Annual population growth rate for year t is the exponential rate of growth of midyear population from year t-1 to t, expressed as a percentage . Population is based on the de facto definition of population, which counts all residents regardless of legal status or citizenship.
2590	SP.POP.TOTL	Total population is based on the de facto definition of population, which counts all residents regardless of legal status or citizenship. The values shown are midyear estimates.
2608	SP.SEC.TOTL.IN	Population of the age-group theoretically corresponding to secondary education as indicated by theoretical entrance age and duration.

Sélection

Indicateurs pertinents - nettoyage

Afin de faire un scoring, j'ai sélectionné une année (2015), et ait pivoté les indicateurs pour qu'ils forment une colonne par pays.

=> Il s'avère que dans les données sélectionnées tous les indicateurs n'étaient pas renseignés pour les pays concernés.

=> Il a fallu nettoyer ce dataset "Final" :

- Éliminer 3 indicateurs ayant trop de valeurs nulles
- Supprimer les lignes restantes avec des valeurs nulles

```
In [224]: redux_1y_indicators
```

```
Out[224]:
```

Indicator Code	NY.GDP.PCAP.CD	NY.GDP.PCAP.KD	NY.GNP.MKTP.CD	SE.SEC.DURS	SP.POP.GROW	SP.POP.TOTL	SP.SEC.TOTL.IN
Country Name							
Afghanistan	569.577923	599.135196	1.938857e+10	6.0	2.943234	3.373649e+07	4850112.0
Albania	3934.895394	4524.990993	1.122583e+10	7.0	-0.291206	2.880703e+06	329011.0
Algeria	4160.220067	4759.595242	1.604671e+11	7.0	1.919959	3.987153e+07	4056674.0
Angola	3695.793748	3730.169063	9.705471e+10	6.0	3.428021	2.785930e+07	3562398.0
Antigua and Barbuda	13659.147914	12771.767577	1.333606e+09	5.0	1.054346	9.992300e+04	7836.0
Argentina	13467.102357	10490.019568	5.735346e+11	6.0	1.009855	4.341776e+07	4204388.0
Australia	56554.038761	54941.911458	1.317479e+12	6.0	1.391107	2.378934e+07	1714038.0
Austria	44255.583356	47834.787303	3.792698e+11	8.0	1.066623	8.633169e+06	690920.0
Azerbaijan	5500.310382	6117.030862	5.104655e+10	7.0	1.191210	9.649341e+06	907062.0
Bahamas, The	29056.090663	20184.735694	1.083740e+10	6.0	1.214308	3.868380e+05	32716.0

```
In [227]: redux_1y_indicators.isna().sum().sum()
```

```
Out[227]: 0
```

```
In [228]: redux_1y_indicators.shape
```

```
Out[228]: (173, 7)
```

=> Au final : 173 pays pour 7 indicateurs sur une année (2015)



03

SCORING

Indicateurs pertinents - nettoyage

On calcule un score pour chaque pays en fonction du score maximal existant pour chaque indicateur, puis on somme ces derniers pour avoir un score final par pays.

Voici les 5 pays ayant les scores les plus élevés, qui sont à priori de bonnes cibles potentielles vis-à-vis de la problématique initiale :

United States	3.204215
Luxembourg	3.183504
India	3.075036
China	3.008079
Switzerland	2.537447
Norway	2.436305



04

CONCLUSION

Conclusion

Pertinence des données :

- Données liées à l'éducation et au développement des pays
- Grand nombre de pays couverts

Limites des données :

- Données manquantes :
 - Pays / zones avec peu de données
 - Indicateurs inutilisables (données manquantes ++)
 - Pas de données après 2016 (prédictions uniquement)
- Besoin de discuter avec les détenteurs du besoin (Academy) pour préciser le besoin : pays visés, langues visées, discuter les indicateurs souhaités, sources complémentaires

Limite de l'étude et du scoring:

Le choix des indicateurs n'est peut-être pas le plus pertinent, il peut être intéressant de revenir sur l'étude (avec l'aide des dépositaires du besoin) pour définir des indicateurs plus pertinents.

Le scoring peut aussi bénéficier d'un nettoyage plus poussé, de l'utilisation de quantiles voire aussi d'une pondération.



Pertinence des données :

- Données liées à l'éducation et au développement des pays
- Grand nombre de pays couverts

Limites des données :

- Données manquantes :
 - Pays / zones avec peu de données
 - Indicateurs inutilisables (données manquantes ++)
 - Pas de données après 2016 (prédictions uniquement)
- Besoin de discuter avec les détenteurs du besoin (Academy) pour préciser le besoin : pays visés, langues visées, discuter les indicateurs souhaités, sources complémentaires

Abstract geometric line art in the top corners of the slide, consisting of interconnected lines and dots forming various shapes.

Merci

Pour votre attention.

GAILLOT Dimitri