



Projet n°2 : “Analyser des données de systèmes éducatifs”

Soutenance de Projet
Gaillot Dimitri

=> [Lien GitHub](#)

SOMMAIRE

01

CONTEXTE

Rappel de la problématique et
présentation du jeu de données

02

ANALYSE

Analyse pré-exploratoire

03

CONCLUSION

Conclusions sur la pertinence
du jeu de données

01

CONTEXTE



CONTEXTE

Entreprise

- Academy est une start-up de la EdTech
- Orienté apprentissage en ligne
- Contenu de formation du niveau lycée et université
- Objectif d'expansion à l'international



academy

Objectif

Informar le projet d'expansion en réalisant une analyse pré-exploratoire et déterminer si les données sur l'éducation de la Banque Mondiale conviennent.

Jeu de données

EdStatsData.csv

Fournit l'évolution de multiples indicateurs pour tous les pays

- **Taille** : 311.3 MB / 886 930 lignes x 70 colonnes
- **Valeurs manquantes** : nombreuses
- **Doublons** : aucun

EdStatsSeries.csv

Informations sur les indicateurs socio-économiques d'EdStatsData

- **Taille** : 3.54 MB / 3665 lignes x 21 colonnes
- **Valeurs manquantes** : 6 colonnes vides
- **Doublons** : aucun

EdStatsCountry.csv

Informations sur l'économie de chaque pays / zone géographique

- **Taille** : 0.13 MB / 241 lignes x 32 colonnes
- **Valeurs manquantes** : quelques valeurs manquantes
- **Doublons** : aucun

EdStatsCountry-Series.csv

Informations sur la source des données d'EdStatsCountry

- **Taille** : 0.05 MB / 613 lignes x 4 colonnes
- **Valeurs manquantes** : aucune (une colonne erronée 'Unnamed : 3')
- **Doublons** : aucun

EdStatsFootNote.csv

Informations sur l'année d'origine et l'incertitude des données

- **Taille** : 37.87 MB / 643 638 lignes x 4 colonnes
- **Valeurs manquantes** : aucune (une colonne erronée 'Unnamed : 4')
- **Doublons** : aucun

Jeu de données

MARS

Despite being red,
Mars is a cold place,
not hot

NEPTUNE

Neptune is the farthest planet from the Sun, the
fourth-largest in our Solar System

JUPITER

It's a gas giant and the
biggest planet in our
Solar System

SATURN

Saturn is a gas giant,
composed of
hydrogen and helium





02

ANALYSE

Analyse Pré-Exploratoire



Vue d'ensemble

Répartition, relations



Qualité

Données exploitables :
Manquantes, anomalies (aberrantes
/ inhabituelles)



Sélection

Choix de données pertinentes,
Réduction du dataset

Données - généralités

1970- 2050


Années, historique & prédictions

241


Zones géographiques

3665


Indicateurs uniques




EDStatsData




EdStatsFootNote



EdStatsCountry





EDStatsData - colonnes Données manquantes



EDStatsData - indicateurs Données disponibles

Les indicateurs présentent entre
40 et 71% de données disponibles



Indicateurs pertinents

3 - Sélection d'indicateurs


	Indicator Code	percent_available	Indicator Name
0	SP.POP.TOTL	98.07	Population, total
1	SP.POP.GROW	98.02	Population growth (annual %)
19	SP.SEC.TOTL.IN	88.30	Population of the official age for secondary education, both sexes (number)
38	SP.TER.TOTL.IN	85.75	Population of the official age for tertiary education, both sexes (number)
48	SE.SEC.DURS	83.18	Theoretical duration of secondary education (years)
51	NY.GDP.PCAP.CD	80.85	GDP per capita (current US\$)
53	NY.GDP.PCAP.KD	78.07	GDP per capita (constant 2005 US\$)
54	NY.GNP.MKTP.CD	77.37	GNI (current US\$)
58	SE.SEC.ENRL.GC	70.55	Enrolment in secondary general, both sexes (number)
67	SE.SEC.ENRL	65.10	Enrolment in secondary education, both sexes (number)

Sélection

Indicateurs pertinents

- 1 - Indicateurs avec 64+ % de données disponibles

- 2 - Etude des indicateurs en prenant en compte leur description



```
In [65]: # describe de ces kpi
# plot value vs time pour chaque kpi
# sélectionner ceux qui semblent cohérents par rapport à ce que l'on voit

pd.set_option('display.max_colwidth', None)
pd.options.display.max_rows = None
values_indicator_2 = values_top_data_2.join(top_data_2[['Indicator Code', 'Indicator Name']].set_index('Indicator Code', 'Indicator Name'))
val_indic_desc = values_indicator_2.drop_duplicates(subset = ['Indicator Code'], keep = 'first').sort_values(by='percent_available', ascending=False)
val_indic_desc
```

Indicator Code	percent_available	Indicator Name
0	98.07	Population, total
1	98.02	Population growth (annual %)
2	90.06	Population, ages 15-64 (% of total)
3	89.97	Population, ages 0-14 (% of total)
4	89.97	Population, male (% of total)
5	89.97	Population, female (% of total)
6	89.70	Population, ages 0-14, female
7	89.70	Population, ages 15-64, female
8	89.70	Population, ages 0-14, male
9	89.70	Population, ages 0-14, total
10	89.70	Population, ages 15-64, male
11	89.70	Population, ages 15-64, total
12	89.70	Population, female
13	89.70	Population, male
14	88.48	Population of the official age for pre-primary education, both sexes (number)
15	88.35	Population of the official age for pre-primary education, female (number)
16	88.35	Population of the official age for pre-primary education, male (number)
17	88.34	Population of the official age for upper secondary education, both sexes (number)
18	88.32	Population of the official age for lower secondary education, both sexes (number)
19	88.30	Population of the official age for secondary education, both sexes (number)
20	88.21	Population of the official age for upper secondary education, male (number)



03

CONCLUSION



Pertinence

- Données liées à l'éducation et au développement des pays
- Grand nombre de pays couverts
- Certains i

Limites

- Données manquantes :
 - Pays / zones avec peu de données
 - Indicateurs inutilisables (données manquantes ++)
 - Pas de données après 2016 (prédictions uniquement)
 - Besoin de discuter avec les détenteurs du besoin (Academy) pour préciser le besoin : pays visés, langues visées, discuter les indicateurs souhaités, sources complémentaires
- 

Abstract geometric line art in the top corners of the slide, consisting of interconnected lines and dots forming various polygonal shapes.

Merci

Pour votre attention.

GAILLOT Dimitri